

神经网络

陈飞宇

fchen@cqu.edu.cn

办公室：软件学院529


How our brain works?




1 大脑半球像半个核桃



2 大脑皮层由灰质白质组成



神经元模型



- x_i : 第 i 个神经元的输入
- w_i : 第 i 个神经元的权重
- θ : 阈值(threshold)或称为偏置 (bias)
- y : 神经元状态 (兴奋或抑制)


激活函数（ Activation function ）

由于单位阶跃函数不是一个连续函数，我们通常选择一些性质好的函数作为替代函数。

Logistic function:


$$y = \frac{1}{1 + e^{-z}}$$

Unit-step function and logistic function




激活函数 (Activation function)

$f(\cdot)$ 函数称为激活函数(activation function)或挤压函数(Squashing function)。



感知机 (Perceptron)

感知机 (Perceptron) 由两层神经元组成，是最简单的神经网络。



感知机 (Perceptron)

对于上述感知机模型, 给定训练点 (x, y) , 令 $w_0 = \theta, x_0 = -1$ (哑结点), 则 $\hat{w}^T \hat{x} = w_1 x_1 + w_2 x_2 + w_0 x_0$ 。

感知机模型为:

$$\min_{\hat{w}} (\hat{y} - y) \hat{w}^T \hat{x}$$

其中 $\hat{y} = f(\hat{w}^T \hat{x})$ 为感知机当前的输出结果。

感知机参数 \hat{w} 的更新公式:

$$\hat{w} \leftarrow \hat{w} - \eta \frac{\partial((\hat{y} - y) \hat{w}^T \hat{x})}{\partial \hat{w}} \leftarrow \hat{w} - \eta (\hat{y} - y) \hat{x}$$

若样例 (x, y) 预测正确 $\Rightarrow \hat{y} = y \Rightarrow \hat{w}$ 不再更新

若样例 (x, y) 预测错误 $\Rightarrow \hat{y} \neq y \Rightarrow \hat{w}$ 继续更新


逻辑运算 I

“与”运算($x_1 \wedge x_2 \wedge \cdots \wedge x_n$), 其中 $x_i \in \{0, 1\}$ 。

令权重 $w_1 = w_2 = \cdots = w_n = 1$, 阈值 $\theta = n$ 。

则输出 $y = f(\sum_{i=1}^n w_i x_i - \theta) = f(\sum_{i=1}^n x_i - n)$

当且仅当 $x_1 = x_2 = \cdots = x_n = 1$ 时,
 $y = 1$ 。




逻辑运算 II

“或”运算($x_1 \vee x_2 \vee \cdots \vee x_n$), 其中 $x_i \in \{0, 1\}$ 。

令权重 $w_1 = w_2 = \cdots = w_n = 1$, 阈值 $\theta = 1/2$.

输出 $y = f(\sum_{i=1}^n w_i x_i - \theta) = f(\sum_{i=1}^n x_i - 1/2)$

当且仅当至少有一个 $x_i = 1$ 时,
 $y = 1$ 。



逻辑运算 III


“非”运算($\sim x_i$), 其中 $x_i \in \{0, 1\}$ 。

令 $w_i = -2$, 其他 $w_j = 0$, 阈值 $\theta = -1$.

输出 $y = f(\sum_{i=1}^n w_i x_i - \theta) = f(-2x_i + 1)$

当 $x_i = 1$ 时, $y = f(-1) = 0$;

当 $x_i = 0$ 时, $y = f(1) = 1$ 。



逻辑运算 IV

“异或”运算($x_i \oplus x_j$), 其中 $x_i \in \{0, 1\}$ 。

若感知机可以解决异或运算, 则


当 $x_i = x_j$ 时, $y = f(\sum_{i=1}^n w_i x_i - \theta) = 0$

$$w_i + w_j - \theta < 0, -\theta < 0$$

当 $x_i \neq x_j$ 时, $y = f(\sum_{i=1}^n w_i x_i - \theta) = 1$


$$w_i - \theta \geq 0, w_j - \theta \geq 0$$

不存在这样的 w_i 和 w_j !!!



感知机原理

考虑二分类问题，**红色点**代表着误分类点。



误分类点

考虑输出变量 $y_i \in \{0, 1\}$, 定义

$$\gamma_i = (\hat{y}_i - y_i) \frac{w^T x_i - \theta}{\|w\|} \geq 0$$

其中 $\hat{y}_i = f(w^T x_i - \theta)$ 。

若 $\hat{y}_i = y_i$, 则 $\gamma_i = 0$; 若 $\hat{y}_i \neq y_i$, 则 $\gamma_i = \frac{|w^T x_i - \theta|}{\|w\|}$

因此 $(\hat{y}_i - y_i)(w^T x_i - \theta)$ 衡量着误分类点 x_i 到分类超平面的距离。

感知机模型

令 $w_0 = \theta, x_0 = -1$, 即将阈值 θ 看作是“哑结点” x_0 所对应的权重, 则感知机最小化**误分类点**到分类平面的距离和:

$$\min_{\hat{w}} \sum_{i=1}^n (\hat{y}_i - y_i) \hat{w}^T \hat{x}_i$$

$\hat{w} = [w_0; w_1; \cdots; w_d]$, $\hat{x}_i = [x_0; x_{i1}; \cdots; x_{id}]$ 。

注意, 上述求和仅当 $\hat{y}_i \neq y_i$ 时起作用!

感知机模型

感知机模型：

$$\min_{\hat{\mathbf{w}}} \sum_{i=1}^n (\hat{y}_i - y_i) \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i$$


梯度下降法：

$$\hat{\mathbf{w}} \leftarrow \hat{\mathbf{w}} - \eta \Delta \hat{\mathbf{w}}$$


其中

$$\Delta \hat{\mathbf{w}} = \frac{\partial (\sum_{i=1}^n (\hat{y}_i - y_i) \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i)}{\partial \hat{\mathbf{w}}} = \sum_{i=1}^n (\hat{y}_i - y_i) \hat{\mathbf{x}}_i = \mathbf{X}^T (\hat{\mathbf{y}} - \mathbf{y})$$

感知机原理



单隐层神经网络



第一层:


$$b_1 = f(v_{11}x_1 + v_{12}x_2 - \theta_1)$$

$$b_2 = f(v_{21}x_1 + v_{22}x_2 - \theta_2)$$

第二层:

$$y = g(w_1b_1 + w_2b_2 - \theta)$$

异或问题



$$b_1 = f(x_1 + x_2 - 0.5)$$

$$b_2 = f(-x_1 - x_2 + 1.5)$$

$$y = g(b_1 + b_2 - 1.5)$$

$$x_1 = 0, x_2 = 0;$$

$$b_1 = 0, b_2 = 1, y = 0$$

$$x_1 = 0, x_2 = 1;$$

$$b_1 = 1, b_2 = 1, y = 1$$


$$x_1 = 1, x_2 = 0;$$

$$b_1 = 1, b_2 = 1, y = 1$$

$$x_1 = 1, x_2 = 1;$$

$$b_1 = 1, b_2 = 0, y = 0$$

异或问题




$$x_1 = 0, x_2 = 0, y = 0$$

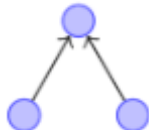

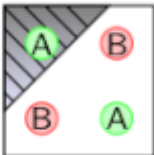
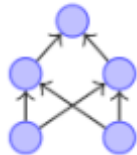

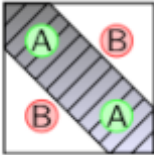
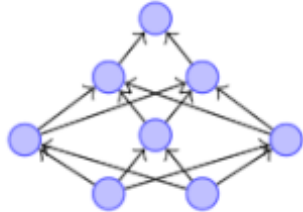


$$x_1 = 0, x_2 = 1, y = 1$$

$$x_1 = 1, x_2 = 0, y = 1$$

$$x_1 = 1, x_2 = 1, y = 0$$




多层神经网络

结构	决策区域类型	区域形状	异或问题
无隐层 	由一超平面分成两个		
单隐层 	开凸区域或闭凸区域		
双隐层 	任意形状（其复杂度由单元数目确定）		

多层前馈神经网络

多层前馈神经网络：每层神经元与下一层神经元完全相连，神经元之间不存在同层连接，也不存在跨层连接。



误差逆传播算法





图 5.7 BP 网络及算法中的变量符号

误差逆传播算法



$$\hat{y}_j^k = f(\beta_j - \theta_j);$$

$$\beta_j = \sum_{h=1}^q \omega_{hj} b_h$$

$$b_h = f(\alpha_h - \gamma_h)$$

$$\alpha_h = \sum_{i=1}^d v_{ih} x_i$$

其中 f 是对数几率函数。

$$f' = f(1 - f)$$

BP网络均方误差:
$$E_k = \frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2$$

误差逆传播算法

$$\hat{y}_j^k = f(\beta_j - \theta_j);$$

$$\beta_j = \sum_{h=1}^q \omega_{hj} b_h$$

$$b_h = f(\alpha_h - \gamma_h)$$

$$\alpha_h = \sum_{i=1}^d v_{ih} x_i$$

其中 f 是对数几率函数。

$$f' = f(1 - f)$$

$$\frac{\partial E_k}{\partial \omega_{hj}} = \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial \omega_{hj}}$$

$$\frac{\partial E_k}{\partial \theta_j} = - \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j}$$

$$\frac{\partial E_k}{\partial v_{ih}} = \sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h} \frac{\partial \alpha_h}{\partial v_{ih}}$$

$$\frac{\partial E_k}{\partial \gamma_h} = - \sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h}$$

$$\frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j}$$

$$E_k = \frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2;$$

$$\hat{y}_j^k = f(\beta_j - \theta_j); \quad \beta_j = \sum_{h=1}^q \omega_{hj} b_h$$

$$\frac{\partial E_k}{\partial \hat{y}_j^k} = \frac{\partial (\frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2)}{\partial \hat{y}_j^k} = \hat{y}_j^k - y_j^k$$

$$\frac{\partial \hat{y}_j^k}{\partial \beta_j} = \frac{\partial f(\beta_j - \theta_j)}{\partial \beta_j} = f(1 - f) = \hat{y}_j^k (1 - \hat{y}_j^k)$$

$$-g_j = \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} = \hat{y}_j^k (1 - \hat{y}_j^k) (\hat{y}_j^k - y_j^k)$$

$$\sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h}$$

$$\beta_j = \sum_{h=1}^q \omega_{hj} b_h; \quad b_h = f(\alpha_h - \gamma_h)$$

$$\frac{\partial \beta_j}{\partial b_h} = \omega_{hj}$$

$$\frac{\partial b_h}{\partial \alpha_h} = \frac{\partial f(\alpha_h - \gamma_h)}{\partial \alpha_h} = f(1 - f) = b_h(1 - b_h)$$

$$\frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h} = b_h(1 - b_h) \omega_{hj}$$

$$e_h = \sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h} = b_h(1 - b_h) \sum_{j=1}^l \omega_{hj} g_j$$

误差逆传播算法

$$\frac{\partial E_k}{\partial \omega_{hj}} = \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial \omega_{hj}} = -g_j b_h$$

$$\frac{\partial E_k}{\partial \theta_j} = -\frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} = g_j$$

$$\frac{\partial E_k}{\partial v_{ih}} = \sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h} \frac{\partial \alpha_h}{\partial v_{ih}} = -e_h x_i$$

$$\frac{\partial E_k}{\partial \gamma_h} = -\sum_{j=1}^l \frac{\partial E_k}{\partial \hat{y}_j^k} \frac{\partial \hat{y}_j^k}{\partial \beta_j} \frac{\partial \beta_j}{\partial b_h} \frac{\partial b_h}{\partial \alpha_h} = e_h$$

迭代公式:

$$\omega_{hj} \leftarrow \omega_{hj} + \eta_{\omega} g_j b_h$$

$$\theta_j \leftarrow \theta_j - \eta_{\theta} g_j$$

$$v_{ih} \leftarrow v_{ih} + \eta_v e_h x_i$$

$$\gamma_h \leftarrow \gamma_h - \eta_{\gamma} e_h$$

其中 $\eta \in (0, 1)$ 为学习率。

误差逆传播算法

BP算法优化准则:

$$\min_{\theta, \omega, \gamma, \nu} E_k = \frac{1}{2} \sum_{j=1} (\hat{y}_j^k - y_j^k)^2$$

其中预测值 \hat{y}_j^k 与权重 $\theta, \omega, \gamma, \nu$ 相关。

梯度下降法:

$$\frac{\partial E_k}{\partial \theta}, \quad \frac{\partial E_k}{\partial \omega}, \quad \frac{\partial E_k}{\partial \gamma}, \quad \frac{\partial E_k}{\partial \nu}$$

BP算法小结

核心思想：利用前向传播，计算第 n 层输出值

优化目标：输出值和实际值的残差。

计算方法：将残差按影响逐步传递回第 $n - 1, n - 2, \dots, 2$ 层，以修正各层参数。（即所谓的误差逆传播）

主要工具：链式法则（复合函数求偏导）。

BP算法局限性

- 容易过拟合！

早停、正则化

- 容易陷入局部最优！

选取多次初值、随机梯度下降法

- 难以设置隐层个数！

试错法